

Modelos IA aplicados para la predicción de la cartera morosa del sistema Bancario Colombiano




UNIVERSIDAD
SERGIO ARBOLEDA

Maestría en Inteligencia Artificial
Javier Ricardo Ceferino Cortés
Tutor: Juan Pablo Ospina




Problema

La morosidad de la cartera de créditos de los Bancos, exponen a **perdidas** los ahorros de las personas y las utilidades de la Banca.



Ciclicidad observada

El comportamiento de la variación del índice de mora permite observar que **hay ciclos semestrales repetitivos** qué, aunque se presentan en diferentes escalas, siguen el mismo patrón de comportamiento



Objetivo General

Desarrollar un **modelo de IA que pronostique** la variación mensual de cartera morosa del sistema Bancario Colombiano.

Objetivos específicos


- **Recopilar datos** Bancarios, agregados económicos y de precios de materias primas claves.
- Determinar los métodos de **aprendizaje automático que permitan pronosticar** la cartera morosa
- Validar el **desempeño de los modelos** generados contra metodologías tradicionales

Esta previsión de los resultados de cartera les permitirá a los Bancos tener un **indicativo que los faculte para anticiparse y tomar los controles preventivos** que consideren pertinentes para optimizar su rentabilidad y/o reorientar su plan de negocio.



Estado del Arte

ML/DL/ST aplicados al riesgo crediticio, medición y prospección de indicadores financieros, stress testing, correlación de agregados macroeconómicos y la Banca



Metodología

Preparación de los datos

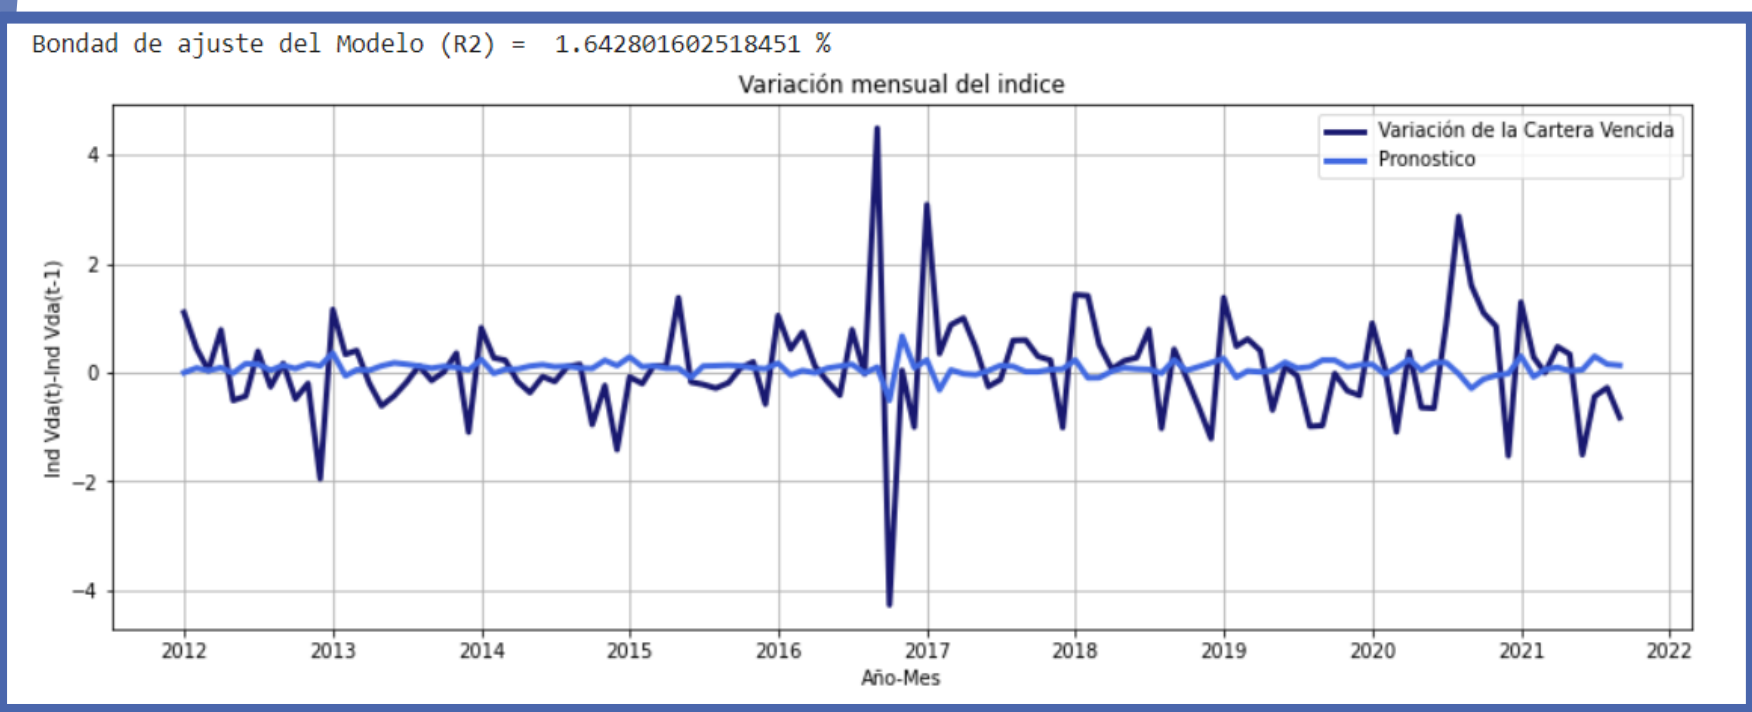
+ Entrenamiento de modelos

+ Validación de modelos


+ Comparación de resultados

Resultados de modelos


Serie de tiempo ARIMA




Estimación general del ciclo



Estimación solo con agregados económicos



Estimación integral del ciclo con los agregados



Conclusiones parciales

El método de menor ajuste fue la serie de tiempo con un ajuste del 1.6%, mientras que los demás modelos se ajustaron mejor:

- 29% la estimación general del ciclo
- 14% con los agregados económicos
- **44% con la visión integrada** de los anteriores 2 modelos

Siguientes pasos

Enriquecer el data set

Evaluar más modelos ML/DL

Establecer la estrategia de validación

Publicar los resultados en una revista de investigación


Fuente de datos: Superintendencia financiera de Colombia, Banco de la república, DANE y precios de materias prima en bolsa (ene/02- dic-21)

Bibliografía

[1] Predicting bank insolvencies using machine learning techniques, [2] Valuation and credit risk in Colombia, [3] Instrumentos Financieros, [4] NIIF 9 - Instrumentos financieros - Entendiendo los elementos claves, [5] Decision-making techniques for credit resource management using machine learning and optimization, [6] Integration of unsupervised and supervised machine learning algorithms for credit risk assessment, [7] Machine learning for financial risk management: A survey, [8] Machine learning in banking risk management: A literature review, [9] Machine learning for financial risk management with Python: algorithms for modeling risk, [10] Machine Learning con Python Aprendizaje supervisado, [11] Data Science for Economics and Finance, [12] Disrupting Finance FinTech and Strategy in the 21st Century, [13] An ensemble machine

learning approach for forecasting credit risk of agricultural SMEs' investments in agriculture 4.0 through supply chain finance, [14] Machine learning techniques for credit risk evaluation: a systematic literature review, [15] Forecasting bank failures and stress testing: a machine learning approach, [16] Predicting bank failure: An improvement by implementing a machine-learning approach to classical financial ratios, [17] Journal of Financial Risk Management, [18] The Impact of Credit Risk Management on Profitability of Commercial Banks: A Study of Europe, [19] Credit Risk Management and Profitability in Commercial Banks in Sweden, [20] The relationship between bank credit risk and profitability and liquidity, [21] Riesgo crediticio en la rentabilidad de créditos oportunos en el banco bsa, [22] The term structure of interest rates and macroeconomic factors: Evidence from Indian financial market, [23] Inteligencia artificial: un

enfoque moderno. Pearson Prentice Hall, 2004., [24] Bank dividends, real gdp growth and default risk, [25] Contribution of macroeconomic factors to the prediction of small bank failures, [26] The impact of banking sector stability on the real economy, [27] The impact of credit risk and macroeconomic factors on profitability: The case of the ASEAN banks, [28] Reconciling theory and empirics on the role of unemployment in mortgage default, [29] Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow Concepts, Tools, and Techniques to Build Intelligent Systems, [30] A macro stress test model of credit risk for the Brazilian banking sector, [31] Stress testing credit risk: a survey of authorities' approaches



LinkedIn



Pdf